

 Institución Universitaria	GUÍA DE TRABAJO PRÁCTICO - EXPERIMENTAL Talleres y Laboratorios de Docencia ITM	Código	FGL 029
		Versión	02
		Fecha	06-03-2019

1. IDENTIFICACIÓN DE LA GUÍA

Nombre de la guía:	Talleres evaluativos de Inteligencia Artificial
Código de la guía (No.):	003
Taller(es) o Laboratorio(s) aplicable(s):	Taller evaluativo en grupos acerca de lógica difusa e introducción al aprendizaje de máquina.
Tiempo de trabajo práctico estimado:	12 días (Entrega: Abril 1 de 2019 antes 20 horas)
Asignatura(s) aplicable(s):	Inteligencia Artificial IA184-3
Programa(s) Académico(s) / Facultad(es):	Ingeniería de sistemas / Departamento de sistemas informacionales
Docente encargado	Carlos Alejandro Trujillo Anaya
Porcentaje evaluado de la asignatura	20%

COMPETENCIAS	CONTENIDO TEMÁTICO	INDICADOR DE LOGRO
El estudiante implementa en lenguaje Python sistemas de lógica difusa (FLS) para la solución de problemas. El estudiante comprende los fundamentos básicos del aprendizaje de máquina. El estudiante plantea problemas que se solucionarán a través de alguna estrategia de aprendizaje de máquina.	Lógica difusa Fundamentos de aprendizaje de máquina: Aprendizaje no supervisado vs supervisado. Fundamentos de algunos algoritmos de aprendizaje de máquina.	Soluciona apropiadamente problemas prácticos empleando estrategias basadas en la lógica difusa. El estudiante comprende los fundamentos del aprendizaje de máquinas. El estudiante plantea problemas para solucionar a través del aprendizaje de máquina.

2. FUNDAMENTO TEÓRICO

La lógica difusa (FLS) es un método de razonamiento que intenta dar cuenta del razonamiento humano. El enfoque en un FLS imita la forma de tomar decisiones de los humanos al involucrar todas las posibilidades intermedias entre los valores digitales SÍ y NO (verdadero - falso). El bloque lógico convencional de un computador toma una entrada precisa (definida) y produce una salida definida como VERDADERO o FALSO, que es equivalente a SÍ o NO de humanos.

El inventor de la lógica difusa, *Lotfi Zadeh*, observó que a diferencia de las computadoras, la toma de decisiones humanas incluye un rango de posibilidades entre SÍ y NO, como: (*Ciertamente sí, Posiblemente sí, No sé, Posiblemente no y Ciertamente no*).

La lógica difusa funciona en términos de las posibilidades de las variables de entrada para lograr una salida definida. Se puede implementar en sistemas con varios tamaños y capacidades que van desde pequeños

	GUÍA DE TRABAJO PRÁCTICO - EXPERIMENTAL Talleres y Laboratorios de Docencia ITM	Código	FGL 029
		Versión	02
		Fecha	06-03-2019

microcontroladores, hasta grandes sistemas de control en red, basados en estaciones de trabajo. Puede implementarse en hardware, software o una combinación de ambos.

La lógica difusa es útil para fines comerciales y prácticos:

- Puede controlar máquinas y productos de consumo.
- Puede no dar un razonamiento preciso, pero un razonamiento aceptable.
- La lógica difusa aporta un mecanismo para atacar la incertidumbre en la ingeniería.

Ventajas de los FLS:

- Los conceptos matemáticos dentro del razonamiento difuso son muy simples.
- Puede modificar un FLS simplemente agregando o eliminando reglas debido a la flexibilidad de la lógica difusa.
- Los sistemas pueden tomar información de entrada ruidosa, distorsionada e imprecisa.
- Los FLS son fáciles de construir y entender.

Desventajas de los FLS:

- No hay un enfoque sistemático para el diseño de FLS.
- Los FLS son comprensibles solo cuando son simples.

Referencia:

https://www.tutorialspoint.com/artificial_intelligence/artificial_intelligence_fuzzy_logic_systems.htm

El aprendizaje de máquina es el estudio científico de algoritmos y modelos estadísticos que se emplean en sistemas informáticos con el fin de llevar a cabo, de manera efectiva, una tarea específica sin utilizar instrucciones explícitas, sino que se basan en patrones e inferencias. Tradicionalmente el aprendizaje de máquina se ha propuesto como un subconjunto de *inteligencia artificial*. Los algoritmos de aprendizaje de máquina construyen un modelo matemático de datos de muestra, conocido como los "*datos de entrenamiento*", para hacer predicciones o decisiones sin estar programados explícitamente para realizar la tarea.

Los algoritmos de aprendizaje de máquina se utilizan en una amplia gama de aplicaciones, como el filtrado de correo electrónico y la visión por computador, campos donde no es factible desarrollar un algoritmo basado en instrucciones específicas para realizar la tarea deseada. El aprendizaje de máquina está estrechamente relacionado con la estadística computacional, la cual se enfoca en hacer predicciones usando computadoras.

Las tareas de aprendizaje de máquina se clasifican en varias categorías. En el aprendizaje **supervisado**, el algoritmo construye un modelo matemático a partir de un conjunto de datos que contiene tanto las entradas como las salidas deseadas (**etiquetas**). Por ejemplo, si la tarea consiste en detectar si una imagen contiene un objeto determinado, los datos de entrenamiento para este algoritmo incluirían imágenes con y sin ese objeto (la entrada), y cada imagen tendría una etiqueta (la salida) que designaría si contenía el objeto o no.

Los algoritmos de **clasificación** y los algoritmos de **regresión** pertenecen al aprendizaje supervisado. Los algoritmos de clasificación se utilizan cuando las salidas están restringidas a un conjunto limitado de valores (**clases**). Para un algoritmo de clasificación que filtra los correos electrónicos, la entrada sería un correo electrónico entrante y la salida sería el nombre de la carpeta en la que se archiva el correo electrónico. Para un algoritmo que identifica correos electrónicos no deseados, la salida sería la predicción de "spam" o "no spam", representada por los valores booleanos verdadero y falso. Por otro lado, los algoritmos de regresión se

 Institución Universitaria	GUÍA DE TRABAJO PRÁCTICO - EXPERIMENTAL Talleres y Laboratorios de Docencia ITM	Código	FGL 029
		Versión	02
		Fecha	06-03-2019

caracterizan por sus salidas continuas, lo que implica que pueden tener cualquier valor dentro de un rango establecido. Ejemplos de valores continuos son la temperatura, la longitud, el precio de un objeto o el porcentaje de coincidencia de una película o serie con nuestros gustos que la plataforma *Netflix* nos provee.

En el aprendizaje **no supervisado**, el algoritmo construye un modelo matemático a partir de un conjunto de datos que contiene solo entradas y ninguna etiqueta de salida. Los algoritmos de aprendizaje no supervisados se utilizan para encontrar la estructura en los datos, como la **agrupación** o clustering. El aprendizaje no supervisado puede descubrir patrones en los datos y puede agrupar las entradas en categorías (minería de datos), como en el *aprendizaje de características*. La **reducción de la dimensionalidad** es el proceso de reducir el número de "características" o entradas en un conjunto de datos sin perder capacidad de abstracción del sistema (entendimiento de los datos).

Referencias:

- John R.; Bennett, Forrest H.; Andre, David; Keane, Martin A. (1996). Automated Design of Both the Topology and Sizing of Analog Electrical Circuits Using Genetic Programming. Artificial Intelligence in Design '96. Springer, Dordrecht. pp. 151–170. doi:10.1007/978-94-009-0279-4_9.
- Bishop, C. M. (2006), Pattern Recognition and Machine Learning, Springer, ISBN 978-0-387-31073-2.
- Machine learning and pattern recognition "can be viewed as two facets of the same field."
- Friedman, Jerome H. (1998). "Data Mining and Statistics: What's the connection?". Computing Science and Statistics. 29 (1): 3–9.

3. OBJETIVO(S)

- Implementar representaciones de un problema de tipo práctico cuya solución se puede obtener a través de sistemas de lógica difusa en Python.
- Caracterizar completamente un problema determinado el cual puede ser resuelto a través de técnicas de aprendizaje de máquina desde sus fundamentos.
- Plantear completamente un problema determinado con el fin de solucionarlo a través de alguna estrategia de aprendizaje de máquina.

4. RECURSOS REQUERIDOS

- Un computador con un compilador de Python actualizado.
- Referencias dadas por el profesor en clase.
- Un computador con un editor de texto para la redacción del informe.

5. PROCEDIMIENTO

Punto 1 (34%):

Implemente un sistema de lógica difusa para el *Controlador de velocidad de un automóvil*.

El sistema tendrá tres entradas nítidas: velocidad, aceleración y distancia al destino.

De igual forma, el sistema debe proporcionar una salida nítida: potencia (o flujo de combustible al motor).

	GUÍA DE TRABAJO PRÁCTICO - EXPERIMENTAL Talleres y Laboratorios de Docencia ITM	Código	FGL 029
		Versión	02
		Fecha	06-03-2019

Determine el rango y las unidades de cada una de las variables de entradas (nítidas) al sistema.

Un esquema para las variables **fusificadas** posibles (*usted puede utilizar otras funciones*) se ilustra en la Figura 1.




Figura 1. Variables de entrada **fusificadas**. Ejemplo.

Fusifique las variables de entrada de acuerdo a:

Velocidad (5 niveles: Demasiado lento, lento, optimo, rápido y demasiado rápido).

Aceleración (3 niveles: Desacelerando, constante, y acelerando).

Distancia al destino (3 niveles: Muy cercana, cercana y distante).

Determine las funciones de pertenencia para cada caso (11 funciones de pertenencia). Visualice las mismas en tres gráficos (una por cada variable fusificada).

Establezca las funciones de pertenencia de la variable de salida fusificada de acuerdo a:

Potencia (5 niveles: Disminuya la potencia considerablemente, disminuya la potencia ligeramente, no cambie la potencia suministrada, incremente la potencia ligeramente, incremente la potencia considerablemente).

Visualice las funciones de pertenencia para la variable de salida fusificada en un gráfico. Un ejemplo se ilustra en la Figura 2.




Figura 2. Variable de salida **fusificadas**. Ejemplo.

Para obtener la salida fusificada, considere las siguientes reglas:

 Institución Universitaria	GUÍA DE TRABAJO PRÁCTICO - EXPERIMENTAL Talleres y Laboratorios de Docencia ITM	Código	FGL 029
		Versión	02
		Fecha	06-03-2019

1. Si la velocidad es demasiado lenta y se está desacelerando, entonces incremente la potencia considerablemente.
2. Si la velocidad es lenta y se está desacelerando, entonces incremente la potencia ligeramente.
3. Si la distancia es cercana entonces disminuya la potencia ligeramente.

Establezca otras dos reglas (que sean coherente con el problema) que le permitan considerar los conjuntos difusos “no cambie la potencia suministrada” y “disminuya la potencia considerablemente”.

Emplee como métodos de defusificación tanto el bisector como el centroide. ¿Qué puede concluir de los resultados en cada caso?

Imprima los valores *nítidos* de entrada (velocidad, aceleración y distancia al destino) así como el valor *nítido* de la salida (potencia suministrada).

Punto 2 (33%):

Caracterice el ejercicio asignado en términos de:

1. Tipo de aprendizaje: supervisado vs no supervisado.
2. Tipo de problema: Clasificación, regresión, *clustering*, reducción de dimensionalidad.
3. Qué estrategia (método o algoritmo) de aprendizaje de máquina emplearía para resolver el problema?

Justifique adecuadamente los 3 puntos anteriores.

Ejercicio asignados por grupo:

Ejercicio grupo 1: Entrada manual de datos. La inexactitud y la duplicación de datos son problemas en negocios importantes para una organización que desea automatizar sus procesos. Los algoritmos de aprendizaje de máquina ML pueden mejorar significativamente la situación. Los programas de ML utilizan los datos descubiertos para mejorar el proceso a medida que se realizan más cálculos. Por lo tanto, las máquinas pueden aprender a realizar tareas de entrada de datos y documentación que requieren mucho tiempo. Además, los trabajadores en el campo del *knowledge discovery* ahora pueden dedicar más tiempo a las tareas de resolución de problemas de mayor valor. Se ha desarrollado una tecnología de procesamiento de lenguaje natural que escanea textos y determina la relación entre conceptos para escribir informes automáticamente.

Ejercicio grupo 2: Detección de spam. La detección de spam es uno de los problemas resueltos por el aprendizaje de máquina ML. Hace algunos años, los proveedores de servicios de correo electrónico utilizaban técnicas basadas en reglas preexistentes para eliminar el correo no deseado. Pero ahora los filtros de spam crean nuevas reglas utilizando ML. Gracias a modelos bioinspirados implementados en sus filtros de spam, Google ahora cuenta con un 0,1 por ciento de error en la tasa de spam. Estos modelos pueden aprender a reconocer los mensajes de correo no deseado y de *phishing* mediante el análisis de reglas en enormes *clusters* de computadoras.

Ejercicio grupo 3: Recomendación de productos. Dado un historial de compras para un cliente y un gran inventario de productos, los modelos aprendizaje de máquina ML pueden identificar aquellos productos en los

	GUÍA DE TRABAJO PRÁCTICO - EXPERIMENTAL Talleres y Laboratorios de Docencia ITM	Código	FGL 029
		Versión	02
		Fecha	06-03-2019

que un cliente estará interesado y es probable que compre. El algoritmo identifica el patrón oculto entre los elementos y se centra en agrupar productos similares. Un modelo de este proceso de decisión permitiría a un programa hacer recomendaciones a un cliente y motivar las compras de productos.

Ejercicio grupo 4: Diagnóstico médico. El aprendizaje de máquina ML en el campo de la medicina mejorará la salud de los pacientes requiriendo costos mínimos. Los casos de uso en este campo consisten normalmente en hacer diagnósticos casi perfectos, recomendar mejores medicamentos, predecir reingresos e identificar pacientes de alto riesgo. Estas predicciones se basan en conjuntos de datos de registros anónimos de pacientes y sus síntomas. La adopción de ML en medicina se está produciendo a un ritmo acelerado a pesar de muchos obstáculos, que pueden ser superados por profesionales y consultores que conocen los obstáculos legales, técnicos y médicos.

Ejercicio grupo 5: Segmentación de clientes. La segmentación de clientes y la predicción de abandono son los principales desafíos que enfrenta cualquier comercializador. Las empresas tienen una gran cantidad de datos de marketing relevantes de diversas fuentes, como campañas de correo electrónico, las visitas de sitios web y datos básicos de clientes potenciales. Al emplear el aprendizaje de máquina ML, se puede lograr una predicción precisa para las ofertas e incentivos de marketing individuales. Al utilizar ML, los expertos en marketing pueden eliminar las conjeturas relacionadas con el marketing basado en datos. Por ejemplo, dado el patrón de comportamiento de un usuario durante un período de prueba y los comportamientos pasados de todos los usuarios, se pueden predecir las posibilidades de conversión del cliente (comprarle a otra empresa). Un modelo de este problema de decisión permitiría que un programa active las intervenciones a los clientes para persuadirlos de que cambien de empresa para comprar sus productos.

Ejercicio grupo 6: Análisis financiero. Debido al gran volumen de datos, la naturaleza cuantitativa y los datos históricos precisos, el aprendizaje de máquina ML se puede utilizar en el análisis financiero. Los casos de uso actuales de ML en finanzas incluyen operaciones algorítmicas, gestión de cartera, detección de fraudes y suscripción de préstamos. El aprendizaje de máquina permitirá evaluaciones continuas de datos para la detección y análisis de anomalías y matices para mejorar la precisión de los modelos y reglas.

Ejercicio grupo 7: Mantenimiento predictivo. La industria manufacturera puede usar aprendizaje de máquina ML para descubrir patrones significativos en los datos en las fábricas. Las prácticas de mantenimiento correctivo y preventivo son costosas e ineficientes. Por otro lado, el mantenimiento predictivo minimiza el riesgo de fallas inesperadas y reduce la cantidad de actividades de mantenimiento preventivo innecesarias. Para el mantenimiento predictivo, se puede construir un sistema de ML que se soporte en los datos históricos de la máquina, herramientas de visualización de flujo de trabajo sobre la misma y un bucle de retroalimentación de las operaciones (qué tan desgastadas terminan las máquinas). Algunas plataformas proveen ejemplos de simulaciones de falla del motor de un avión. Bajo el supuesto de que el motor tiene un patrón de degradación progresivo, el mismo se evidencia en la medición de un sensor implementado en el motor. Para predecir fallas futuras, el algoritmo aprende la relación entre el valor del sensor y los cambios en los valores del sensor a fallas históricas.

Ejercicio grupo 8: Reconocimiento de imágenes (visión artificial). La visión artificial produce información numérica o simbólica de imágenes y datos de alta dimensión. Involucra el aprendizaje de máquinas, la extracción de datos, descubrimiento de conocimiento en bases de datos de imágenes y reconocimiento de patrones. Los posibles usos comerciales de la tecnología de reconocimiento de imagen se encuentran en la asistencia sanitaria, automóviles: automóviles sin conductor, campañas de marketing, entre otros. Existen empresas que han desarrollado prototipos para personas con discapacidades visuales que incorporan tecnología de visión artificial para captar los alrededores y narrar la interpretación a través de un auricular.

Ejercicio grupo 9: Reconocimiento de voz. El reconocimiento de voz es la traducción de palabras habladas al texto. Una aplicación de software puede reconocer las palabras habladas en un clip de audio o archivo, y luego

	GUÍA DE TRABAJO PRÁCTICO - EXPERIMENTAL Talleres y Laboratorios de Docencia ITM	Código	FGL 029
		Versión	02
		Fecha	06-03-2019

convertir el audio en un archivo de texto. La medición en esta aplicación puede ser un conjunto de números que representan la señal de voz. También se puede segmentar la señal de la voz por intensidades en diferentes bandas de frecuencia. El reconocimiento de voz se usa en aplicaciones en sus interfaces de usuario (*Siri* de Apple es un ejemplo), búsquedas por voz entre otras.

Ejercicio grupo 10: Arbitraje estadístico. En finanzas, el arbitraje se refiere a las estrategias comerciales automatizadas que son de corto plazo e involucran una gran cantidad de títulos. En estas estrategias, el usuario se enfoca en implementar el algoritmo de negociación para un conjunto de títulos sobre la base de cantidades como las correlaciones históricas y las variables económicas generales. Los métodos de aprendizaje de máquina se aplican para obtener una estrategia de índice de arbitraje: se pueden aplicar distintos modelos predictivos para los precios en un flujo de acciones.

Ejercicio grupo 11: Detección de formas. Dado el dibujo (o intento de dibujo) de una forma por parte de un usuario en una pantalla táctil y una base de datos de formas conocidas, se puede determinar qué forma intentaba dibujar el usuario. Un modelo de esta decisión permite a un programa visualizar la versión ideal de esa forma que el usuario ha dibujado para hacer diagramas o figuras más nítidas. La aplicación de iPhone *Instaviz* emplea este modelo.

Ejercicio grupo 12: Detección de rostros. Dado un álbum de fotos digitales de cientos de fotografías digitales, se puede identificar las fotos que incluyen a una persona determinada. Un modelo de este proceso de decisión permitiría a un programa organizar fotos por persona. Algunas cámaras y softwares como *iPhoto* tienen esta capacidad.

Ejercicio grupo 13: Apuestas deportivas. El mundo del deporte provee gran abundancia de datos. Los datos de los equipos, juegos, puntuaciones y jugadores se rastrean y están disponibles gratuitamente en línea. Hay centenares de aplicaciones basadas en aprendizaje de máquinas orientadas a las apuestas deportivas. Predecir los puntajes de los equipos (ganador en partido y goles anotados por ejemplo) justo antes de cada nuevo juego permite a las casas de apuestas establecer las cuotas para las distintas apuestas. **Aclaración: No se está incitando a los estudiantes a involucrarse en el mundo de las apuestas, solo se describe una aplicación del aprendizaje de máquinas.**

Problema 3 (33%):

A partir de problema que le ha sido asignado, y de la estrategia (método o algoritmo) de aprendizaje de máquina que ha determinado en el punto 2, plantee completamente el problema. Lo anterior implica:

1. Determine posibles conjuntos de entrenamiento y validación.
2. Determine las características (atributos) que podrían tener los datos.
3. ¿En este problema los datos tendrán etiquetas? En caso afirmativo describa las posibles clases.
4. Una vez usted alcanza un modelo ajustado, después de un apropiado entrenamiento del mismo empleando el conjunto de datos, ¿qué tan descriptivo puede ser este modelo respecto a los datos y respecto al problema?

6. PARÁMETROS PARA ELABORACIÓN DEL INFORME

 Institución Universitaria	GUÍA DE TRABAJO PRÁCTICO - EXPERIMENTAL Talleres y Laboratorios de Docencia ITM	Código	FGL 029
		Versión	02
		Fecha	06-03-2019

El informe debe incluir las respuestas a las preguntas suministradas en esta guía así como los argumentos solicitados.

No se extienda en teoría general, solo utilice aquella que le ayude a justificar sus respuestas.

7. REFERENCIAS

- <https://machinelearningmastery.com/a-tour-of-machine-learning-algorithms/>
- <https://machinelearningmastery.com/classification-versus-regression-in-machine-learning/>
- Machine Learning Tom M. Mitchell, McGraw-Hill Science/Engineering/Math (1997).
- Understanding Machine Learning: From Theory to Algorithms, Shai Shalev-Shwartz and Shai Ben-David. Cambridge University Press. 2014.
- <https://machinelearningmastery.com/classification-and-regression-trees-for-machine-learning/>
- <https://machinelearningmastery.com/naive-bayes-for-machine-learning/>
- <https://machinelearningmastery.com/k-nearest-neighbors-for-machine-learning/>
- <https://machinelearningmastery.com/support-vector-machines-for-machine-learning/>
- <https://machinelearningmastery.com/logistic-regression-for-machine-learning/>
- <https://machinelearningmastery.com/linear-regression-for-machine-learning/>
- <https://www.datascience.com/blog/k-means-clustering>
- <https://www.geeksforgeeks.org/dimensionality-reduction/>
- <https://machinelearningmastery.com/what-is-deep-learning/>
- <https://skymind.ai/wiki/neural-network>

Elaborado por:	Carlos Alejandro Trujillo Anaya
Revisado por:	Carlos Alejandro Trujillo Anaya
Versión:	001
Fecha:	Marzo 20 de 2019