

 Institución Universitaria	GUÍA DE TRABAJO PRÁCTICO - EXPERIMENTAL Talleres y Laboratorios de Docencia ITM	Código	FGL 029
		Versión	02
		Fecha	06-03-2019

1. IDENTIFICACIÓN DE LA GUÍA

Nombre de la guía:	Talleres evaluativos de Inteligencia Artificial
Código de la guía (No.):	005
Taller(es) o Laboratorio(s) aplicable(s):	Taller evaluativo en grupos (3 estudiantes) acerca de regresión y descenso del gradiente.
Tiempo de trabajo práctico estimado:	15 días (Entrega: Mayo 13 de 2019 antes 20 horas)
Asignatura(s) aplicable(s):	Inteligencia Artificial IA184-3
Programa(s) Académico(s) / Facultad(es):	Ingeniería de sistemas / Departamento de sistemas informacionales
Docente encargado	Carlos Alejandro Trujillo Anaya
Porcentaje evaluado de la asignatura	20%

COMPETENCIAS	CONTENIDO TEMÁTICO	INDICADOR DE LOGRO
El estudiante implementa en lenguaje Python técnicas básicas de <i>machine learning</i> orientadas a la tarea de regresión. El estudiante comprende y aplica técnicas de medición de desempeño de regresores. El estudiante hace uso del algoritmo del descenso del gradiente para la solución de problemas de optimización. El estudiante implementa las distintas variantes del algoritmo del descenso del gradiente para el ajuste de modelos descriptivos.	Regresión lineal simple. Regresión OLRS. Error de regresión RMSE. Métodos de regularización. Descenso del gradiente. Descenso del gradiente estocástico. Rata de aprendizaje. Correlación.	Para un conjunto de datos dado (<i>dataset</i>), el estudiante implementa adecuadamente algoritmos de <i>machine learning</i> para llevar a cabo la tarea de regresión sobre un subconjunto de validación y cuantifica el desempeño del método implementado apropiadamente. El estudiante halla el mínimo global de una función convexa empleando el algoritmo del descenso del gradiente. El estudiante entrena modelos descriptivos empleando el descenso del gradiente y/o alguna de sus variantes.

2. FUNDAMENTO TEÓRICO

Regresión

La tarea de regresión en *machine learning* consiste en ajustar un modelo predictivo que permita aproximar una función de mapeo (f) entre las variables de entrada (X) a una variable de salida continua (y). Una variable de

 Institución Universitaria	GUÍA DE TRABAJO PRÁCTICO - EXPERIMENTAL Talleres y Laboratorios de Docencia ITM	Código	FGL 029
		Versión	02
		Fecha	06-03-2019

salida continua es un valor real, como por ejemplo un valor entero o uno flotante. Estos valores a menudo representan cantidades, tales como pesos y tamaños. Por ejemplo, se puede predecir el salario de una persona a partir de variables como sus estudios, su edad, sus años de experiencia, entre otras. Un problema de regresión consiste entonces en la predicción de una *cantidad*. Una regresión puede tener variables de entrada reales o discretas, como se explicó en el ejemplo anterior. Un problema de regresión con múltiples variables de entrada a menudo se llama un problema de regresión *multivariable*. Por otro lado, un problema de regresión donde las variables de entrada están ordenadas en el tiempo se denomina problema de pronóstico de *series de tiempo*.

Debido a que un modelo predictivo de regresión arroja una cantidad, el desempeño del mismo debe representarse como el error en esas predicciones. Hay muchas formas de estimar este error, pero quizás la más común sea calcular la raíz del error cuadrático medio, abreviado por el acrónimo RMSE por sus siglas en inglés. Un beneficio del RMSE es que sus unidades son las mismas que aquellas de la variable que se predice.

En este punto del curso es importante tener en cuenta un par de cosas: Algunos algoritmos tienen la palabra "regresión" en su nombre, como la regresión lineal y la regresión logística. Lo anterior puede llevar a confusiones considerando que la regresión lineal es un algoritmo de regresión, mientras que la regresión logística es un algoritmo de clasificación.

Descenso del gradiente

El descenso de gradiente es un algoritmo de optimización iterativo que se emplea para encontrar el mínimo de una función que tenga derivada en un dominio dado. Para encontrar el mínimo local (o global) de una función empleando este algoritmo, se determina inicialmente un punto aleatorio en el dominio seguido de pasos proporcionales en las siguientes iteraciones de acuerdo a la dirección que proporcione el negativo del gradiente (o gradiente aproximado) de la función en el punto actual.

El descenso del gradiente se utiliza igualmente para encontrar los parámetros óptimos en los modelos descriptivos de regresión lineal, regresión logística, máquinas de vectores de soporte, así como también en las redes neuronales, *las cuales consideraremos más adelante en este curso*. En este caso, la función a optimizar es la función de *pérdida* (o de *costo*) del modelo. Para algunos modelos, como por ejemplo la regresión logística o las máquinas de vectores de soporte, el criterio de optimización es convexo. Las funciones convexas solo tienen un mínimo, el cual es el mínimo global. Por otro lado, los criterios de optimización para redes neuronales no son convexas, aun así, en la práctica, incluso encontrando un mínimo local se puede obtener un modelo descriptivo aceptablemente ajustado en términos prácticos.

El descenso del gradiente es sensible a dos factores: i) el escalamiento de los datos y ii) a la tasa de aprendizaje. La primera es una operación en la que el rango de los datos de las características que componen al conjunto de entrenamiento se iguala con el fin de que no haya características que predominen en el proceso de optimización. La segunda es el *hiperparámetro* que nos permite determinar qué tanto se considera del negativo gradiente a la hora de actualizar el valor de los coeficientes del modelo descriptivo en una iteración dada. Si se desea un resultado del entrenamiento del modelo satisfactorio, la tasa de aprendizaje no debería ser muy grande (recomendado menor al 20%). Lo anterior implica que al trabajar con conjuntos de datos grandes (millones de instancias y decenas de miles de características), el algoritmo es particularmente lento ya que cada actualización de los valores de los coeficientes se hace una vez se han testeado todas las instancias. Afortunadamente, se han reportado varias mejoras para este algoritmo.

El descenso del gradiente estocástico SGD es un método de optimización para problemas de optimización sin restricciones. En contraste con el descenso del gradiente por lotes (*batch* GD o simplemente descenso del

 Institución Universitaria	GUÍA DE TRABAJO PRÁCTICO - EXPERIMENTAL Talleres y Laboratorios de Docencia ITM	Código	FGL 029
		Versión	02
		Fecha	06-03-2019

gradiente), donde un lote es todo el conjunto de entrenamiento, el SGD se aproxima al gradiente verdadero considerando una sola instancia de entrenamiento a la vez. El descenso de gradiente estocástico de minilotes (*minibatch* SGD) es una versión del algoritmo que acelera el cálculo aproximando el gradiente utilizando lotes más pequeños (subconjuntos) de los datos de entrenamiento. El algoritmo del SGD en sí tiene varias mejoras. *Adagrad* es una versión del SGD que en la que se escala cada parámetro de acuerdo con el historial de gradientes. Como resultado, se reduce para gradientes muy grandes y se aumenta para gradientes muy pequeños. *Momentum* es un método que ayuda a acelerar el SGD al orientar el descenso del gradiente en la dirección correspondiente y reducir las oscilaciones. En el entrenamiento de redes neuronales, las variantes de SGD, como *RMSprop* y *Adam* las cuales se estudiarán posteriormente, se utilizan con mucha frecuencia.

3. OBJETIVO(S)

- Implementar algoritmos básicos de *machine learning* (OLSR, *regresión LASSO* y *RIDGE*) en el marco de la solución de un problema de regresión.
- Validar los regresores implementados haciendo uso de la raíz del error cuadrático medio RMSE.
- Implementar el algoritmo del descenso del gradiente para la optimización de problemas de minimización de funciones.
- Implementar el descenso del gradiente estocástico y/o alguna de sus modificaciones para ajustar los parámetros de los modelos descriptivos estudiados en el curso.

4. RECURSOS REQUERIDOS

- Un computador con un compilador de Python actualizado.
- Referencias dadas por el profesor en clase.
- Un computador con un editor de texto para la redacción del informe.

5. PROCEDIMIENTO

Ejercicio 1:

Encontrar el valor (para x y para y) que minimiza **una** función real de tres coordenadas $z = f(x, y)$, empleando el algoritmo del descenso del gradiente (o alguna de sus variantes).

La función para minimizar debe ser seleccionada de (<https://www.sfu.ca/~ssurjano/optimization.html>). Cada grupo de trabajo debe minimizar una función **distinta**.

Considere los rangos de búsqueda dados en el link en su implementación. El reto consiste en encontrar la solución en menos de 50 iteraciones con una incertidumbre menor a 0.01 para la variable z .

Se recomienda emplear como código base aquel del libro de Burkov, capítulo 4.

Ejercicio 2:

Seleccione del repositorio UCI (<http://archive.ics.uci.edu/ml/datasets.html>) un *dataset* para regresión. Cada grupo de trabajo debe seleccionar un *dataset* distinto.

 Institución Universitaria	GUÍA DE TRABAJO PRÁCTICO - EXPERIMENTAL Talleres y Laboratorios de Docencia ITM	Código	FGL 029
		Versión	02
		Fecha	06-03-2019

Haciendo uso del *dataset* de regresión seleccionado, implemente tres regresores que se ajusten vía SGD o alguna de sus variantes basados en los modelos descriptivos de i) mínimos cuadrados ordinarios (OLSR), ii) LASSO y iii) RIDGE. Evalúe, tanto por validación cruzada como vía RMSE el desempeño de cada uno de tres los regresores. El reto consiste en obtener un error de regresión por debajo del 10%. Para las variables seleccionadas para llevar a cabo el modelo de regresión, determine tipo de relación; justifique cuantitativamente su respuesta (emplee los coeficientes de Pearson o Spearman, según sea el caso).

Se recomienda hacer uso de las funciones que provee el paquete *sci-kit learn* en Python:

https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.SGDRegressor.html

6. INFORME Y SUSTENTACIÓN

El informe debe incluir las respuestas a las preguntas suministradas en esta guía así como los argumentos solicitados.

No se extienda en teoría general, solo utilice aquella que le ayude a justificar sus respuestas.

La sustentación del código enviado se hará en el aula de clase. Debe tener conocimiento de cada una de las estrategias de regresión ya que la sustentación incluirá conocimiento teórico. Todos los integrantes del grupo de trabajo deben prepararse para la sustentación del trabajo. La sustentación corresponderá a una nota *individual*. Si no asiste a la sesión de sustentación, se le asignará un 0.0 en la nota de este trabajo.

7. REFERENCIAS

- Andriy Burkov, "The Hundred-Page Machine Learning Book", 2018.
- Shai, "Understanding Machine Learning: From Theory to Algorithms", 2014.
- <https://machinelearningmastery.com/gradient-descent-for-machine-learning/>
- <https://machinelearningmastery.com/implement-linear-regression-stochastic-gradient-descent-scratch-python/>

Elaborado por:	Carlos Alejandro Trujillo Anaya
Revisado por:	Carlos Alejandro Trujillo Anaya
Versión:	001
Fecha:	Abril 29 de 2019