

 Institución Universitaria	GUÍA DE TRABAJO PRÁCTICO - EXPERIMENTAL Talleres y Laboratorios de Docencia ITM	Código	FGL 029
		Versión	02
		Fecha	06-03-2019

1. IDENTIFICACIÓN DE LA GUÍA

Nombre de la guía:	Talleres evaluativos de Inteligencia Artificial
Código de la guía (No.):	004
Taller(es) o Laboratorio(s) aplicable(s):	Taller evaluativo en grupos (3 estudiantes) acerca de clasificadores básicos.
Tiempo de trabajo práctico estimado:	15 días (Entrega: Abril 17 de 2019 antes 22 horas)
Asignatura(s) aplicable(s):	Inteligencia Artificial IA184-3
Programa(s) Académico(s) / Facultad(es):	Ingeniería de sistemas / Departamento de sistemas informacionales
Docente encargado	Carlos Alejandro Trujillo Anaya
Porcentaje evaluado de la asignatura	10%

COMPETENCIAS	CONTENIDO TEMÁTICO	INDICADOR DE LOGRO
El estudiante implementa en lenguaje Python técnicas básicas de <i>machine learning</i> orientadas a la tarea de clasificación. El estudiante comprende y aplica técnicas de medición de desempeño de clasificadores. El estudiante soluciona problemas a través de estrategias de <i>machine learning</i> .	Clasificador k-NN. Algoritmo <i>Naive Bayes</i> . Regresión logística. Validación cruzada. Precisión de clasificación.	Para un conjunto de datos dado (<i>dataset</i>), el estudiante implementa adecuadamente algoritmos de <i>machine learning</i> para llevar a cabo la tarea de clasificación sobre un subconjunto de validación y cuantifica el desempeño del método implementado apropiadamente.

2. FUNDAMENTO TEÓRICO

k-Nearest Neighbors (k-NN) es un algoritmo de clasificación no paramétrico. Al contrario de otros algoritmos de aprendizaje que permiten descartar los datos de entrenamiento una vez que se construye el modelo, k-NN mantiene todas las muestras de entrenamiento en la memoria. Una vez que aparece una nueva muestra x no vista previamente, el algoritmo k-NN encuentra los k vecinos más próximos en el espacio de características a x y devuelve la etiqueta más votada por estos vecinos. La proximidad de dos muestras viene dada por una función de distancia. La distancia euclidiana es la más popular de las métricas de similitud cuando las características vienen representadas por números reales, sin embargo, otra opción útil es la similitud coseno la cual se emplea cuando las características son categóricas.

Otro de los clasificadores básicos es la *regresión logística*. Este método se basa en un análisis de regresión cuando la variable dependiente es dicotómica (binaria). Se puede resumir como un modelo predictivo de regresión lineal que se acompaña con una función *sigmoide* de salida (función logística). La regresión logística se utiliza para describir datos y para explicar la relación entre una variable binaria dependiente y una o más variables independientes nominales, ordinales, de intervalo o de relación.

 Institución Universitaria	GUÍA DE TRABAJO PRÁCTICO - EXPERIMENTAL Talleres y Laboratorios de Docencia ITM	Código	FGL 029
		Versión	02
		Fecha	06-03-2019

Finalmente, en esta parte del curso trabajaremos con el algoritmo de *Naive Bayes*. Este algoritmo permite llevar a cabo clasificación binaria (de dos clases) y de múltiples clases. Se llama *Bayes ingenuo* porque el cálculo de las probabilidades para cada clase se simplifica para hacerlo más manejable: en lugar de calcular los valores de cada atributo de forma relacionada, los mismos se suponen **condicionalmente independientes**. La anterior es una suposición muy poco probable cuando se trabaja con datos reales, sin embargo, esta estrategia se desempeña sorprendentemente bien en *datasets* donde la suposición no se cumple.

3. OBJETIVO(S)

- Implementar algoritmos básicos de *machine learning* (*k*-NN, *Naive Bayes* y regresión logística) en el marco de la solución de un problema de clasificación.
- Validar los clasificadores implementados haciendo uso de la validación cruzada y de la precisión de clasificación.

4. RECURSOS REQUERIDOS

- Un computador con un compilador de Python actualizado.
- Referencias dadas por el profesor en clase.
- Un computador con un editor de texto para la redacción del informe.

5. PROCEDIMIENTO

Del repositorio UCI (<https://archive.ics.uci.edu/ml/datasets.html>) escoja un *dataset* para clasificación. Envíe el link del *dataset* escogido al profesor para su validación y aprobación. Todos los grupos de trabajo deben escoger un *dataset* distinto.

Para este *dataset*, determine el porcentaje en el cual dividirá los conjuntos de entrenamiento y de validación. Justifique su elección.

Para el *dataset* seleccionado, implemente el clasificador *k*-NN. Valide su desempeño empleando las métricas de precisión de clasificación (*accuracy*) y la validación cruzada. ¿Qué puede concluir a partir de los resultados obtenidos en ambos casos?

Para el *dataset* seleccionado, implemente el clasificador *Naive Bayes*. Valide su desempeño empleando las métricas de precisión de clasificación (*accuracy*) y la validación cruzada. ¿Qué puede concluir a partir de los resultados obtenidos en ambos casos?

Para el *dataset* seleccionado, implemente el clasificador de regresión logística. Valide su desempeño empleando las métricas de precisión de clasificación (*accuracy*) y la validación cruzada. ¿Qué puede concluir a partir de los resultados obtenidos en ambos casos?

La sustentación del código enviado se hará en el aula de clase. Debe tener conocimiento de cada una de las tres estrategias de clasificación ya que la sustentación incluirá conocimiento teórico. Del grupo de trabajo, se seleccionará un estudiante para hacer la sustentación para todo el grupo (la sustentación de los tres estudiantes

 Institución Universitaria	GUÍA DE TRABAJO PRÁCTICO - EXPERIMENTAL Talleres y Laboratorios de Docencia ITM	Código	FGL 029
		Versión	02
		Fecha	06-03-2019

la hará un solo estudiante escogido por el profesor). Si uno de los estudiantes del grupo de trabajo no asiste a clase, el grupo no podrá hacer sustentación.

6. PARÁMETROS PARA ELABORACIÓN DEL INFORME

El informe debe incluir las respuestas a las preguntas suministradas en esta guía así como los argumentos solicitados.

No se extienda en teoría general, solo utilice aquella que le ayude a justificar sus respuestas.

7. REFERENCIAS

- Andriy Burkov, "The Hundred-Page Machine Learning Book", 2018.
- Shai, "Understanding Machine Learning: From Theory to Algorithms", 2014.
- <https://machinelearningmastery.com/k-nearest-neighbors-for-machine-learning/>
- <https://machinelearningmastery.com/logistic-regression-for-machine-learning/>
- <https://machinelearningmastery.com/linear-regression-for-machine-learning/>

Elaborado por:	Carlos Alejandro Trujillo Anaya
Revisado por:	Carlos Alejandro Trujillo Anaya
Versión:	001
Fecha:	Abril 3 de 2019