

 Institución Universitaria	GUÍA DE TRABAJO PRÁCTICO - EXPERIMENTAL Talleres y Laboratorios de Docencia ITM	Código	FGL 029
		Versión	02
		Fecha	06-03-2019

1. IDENTIFICACIÓN DE LA GUÍA

Nombre de la guía:	Talleres preparativos de Inteligencia Artificial I
Código de la guía (No.):	001
Taller(es) o Laboratorio(s) aplicable(s):	Taller preparativo acerca del descenso del gradiente y la tasa de aprendizaje.
Tiempo de trabajo práctico estimado:	7 días
Asignatura(s) aplicable(s):	Inteligencia Artificial IAW92-1
Programa(s) Académico(s) / Facultad(es):	Ingeniería electrónica/ Departamento de electrónica y telecomunicaciones.
Docente encargado	Carlos Alejandro Trujillo Anaya

COMPETENCIAS	CONTENIDO TEMÁTICO	INDICADOR DE LOGRO
El estudiante comprende el algoritmo del descenso del gradiente para la solución de problemas de optimización. El estudiante implementa las distintas variantes del algoritmo del descenso del gradiente para el ajuste de modelos descriptivos.	Descenso del gradiente. Descenso del gradiente estocástico. Rata de aprendizaje. Descenso del gradiente en lotes. Descenso del gradiente en minilotes.	Halla el mínimo global de una función convexa empleando el algoritmo del descenso del gradiente. Entrena modelos descriptivos empleando el descenso del gradiente y/o alguna de sus variantes.

2. FUNDAMENTO TEÓRICO

El descenso de gradiente es un algoritmo de optimización iterativo que se emplea para encontrar el mínimo de una función que tenga derivada en un dominio dado. Para encontrar el mínimo local (o global) de una función empleando este algoritmo, se determina inicialmente un punto aleatorio en el dominio seguido de pasos proporcionales en las siguientes iteraciones de acuerdo a la dirección que proporcione el negativo del gradiente (o gradiente aproximado) de la función en el punto actual.

El descenso del gradiente se utiliza igualmente para encontrar los parámetros óptimos en los modelos descriptivos de regresión lineal, regresión logística, máquinas de vectores de soporte, así como también en las redes neuronales, *las cuales consideraremos más adelante en este curso*. En este caso, la función a optimizar es la función de *pérdida* (o de *costo*) del modelo. Para algunos modelos, como por ejemplo la regresión logística o las máquinas de vectores de soporte, el criterio de optimización es convexo. Las funciones convexas solo tienen un mínimo, el cual es el mínimo global. Por otro lado, los criterios de optimización para redes neuronales no son convexas, aun así, en la práctica, incluso encontrando un mínimo local se puede obtener un modelo descriptivo aceptablemente ajustado en términos prácticos.

El descenso del gradiente es sensible a dos factores: i) el escalamiento de los datos y ii) a la tasa de aprendizaje. La primera es una operación en la que el rango de los datos de las características que componen al conjunto de entrenamiento se iguala con el fin de que no haya características que predominen en el proceso de optimización. La segunda es el *hiperparámetro* que nos permite determinar qué tanto se considera del negativo

 Institución Universitaria	GUÍA DE TRABAJO PRÁCTICO - EXPERIMENTAL Talleres y Laboratorios de Docencia ITM	Código	FGL 029
		Versión	02
		Fecha	06-03-2019

gradiente a la hora de actualizar el valor de los coeficientes del modelo descriptivo en una iteración dada. Si se desea un resultado del entrenamiento del modelo satisfactorio, la tasa de aprendizaje no debería ser muy grande (recomendado menor al 20%). Lo anterior implica que al trabajar con conjuntos de datos grandes (millones de instancias y decenas de miles de características), el algoritmo es particularmente lento ya que cada actualización de los valores de los coeficientes se hace una vez se han testeado todas las instancias. Afortunadamente, se han reportado varias mejoras para este algoritmo.

El descenso del gradiente estocástico SGD es un método de optimización para problemas de optimización sin restricciones. En contraste con el descenso del gradiente por lotes (*batch* GD o simplemente descenso del gradiente), donde un lote es todo el conjunto de entrenamiento, el SGD se aproxima al gradiente verdadero considerando una sola instancia de entrenamiento a la vez. El descenso de gradiente estocástico de minilotes (*minibatch* SGD) es una versión del algoritmo que acelera el cálculo aproximando el gradiente utilizando lotes más pequeños (subconjuntos) de los datos de entrenamiento. El algoritmo del SGD en sí tiene varias mejoras. *Adagrad* es una versión del SGD que en la que se escala cada parámetro de acuerdo con el historial de gradientes. Como resultado, se reduce para gradientes muy grandes y se aumenta para gradientes muy pequeños. *Momentum* es un método que ayuda a acelerar el SGD al orientar el descenso del gradiente en la dirección correspondiente y reducir las oscilaciones. En el entrenamiento de redes neuronales, las variantes de SGD, como *RMSprop* y *Adam* las cuales se estudiarán posteriormente, se utilizan con mucha frecuencia.

3. OBJETIVO(S)

- Implementar en lenguaje *Python* el algoritmo del descenso del gradiente para la optimización de problemas de minimización de funciones.
- Implementar el descenso del gradiente estocástico y/o alguna de sus modificaciones para ajustar los parámetros de los modelos descriptivos estudiados en el curso.

4. RECURSOS

- Un computador con un compilador de Python actualizado.
- Texto guía de la asignatura y referencias que provee el profesor.

5. PROCEDIMIENTO

Ejercicio 1:

Encontrar el valor (para x y para y) que minimiza **una** función real de tres coordenadas $z = f(x, y)$, empleando el algoritmo del descenso del gradiente (o alguna de sus variantes).

Las funciones para minimizar son (escoja **una**):

Rosenbrock (tres coordenadas)

$$z = f(x, y) = (1 - x)^2 + 100(y - x^2)^2$$

Rango de búsqueda: $[-5, 5]$ en x , $[-5, 5]$ en y .

Beale

$$z = f(x, y) = (1.5 - x + xy)^2 + (2.25 - x + xy^2)^2 + (2.625 - x + xy^3)^2$$

 Institución Universitaria	GUÍA DE TRABAJO PRÁCTICO - EXPERIMENTAL Talleres y Laboratorios de Docencia ITM	Código	FGL 029
		Versión	02
		Fecha	06-03-2019

Rango de búsqueda: $[-5, 5]$ en x , $[-5, 5]$ en y .

Goldstein–Price

$$z = f(x, y) = \left[1 + (x + y + 1)^2 (19 - 14x + 3x^2 - 14y + 6xy + 3y^2) \right] \\ \times \left[30 + (2x - 3y)^2 (18 - 32x + 12x^2 + 48y - 36xy + 27y^2) \right]$$

Rango de búsqueda: $[-5, 5]$ en x , $[-4, 4]$ en y .

Booth

$$z = f(x, y) = (x + 2y - 7)^2 + (2x + y - 5)^2$$

Rango de búsqueda: $[-10, 10]$ en x , $[-10, 10]$ en y .

Matyas

$$z = f(x, y) = 0.26(x^2 + y^2) - 0.48xy$$

Rango de búsqueda: $[-10, 10]$ en x , $[-10, 10]$ en y .

Considere los rangos de búsqueda en su implementación. El reto consiste en encontrar la solución en menos de 100 iteraciones con una incertidumbre menor a 0.01 para la variable z .

Se recomienda emplear como código base aquel del libro de Burkov, capítulo 4.

Ejercicio 2:

Seleccione del repositorio UCI (<http://archive.ics.uci.edu/ml/datasets.html>) dos *datasets*: uno para regresión y uno para clasificación.

Haciendo uso del *dataset* de regresión, implemente tres regresores que se ajusten vía SGD o alguna de sus variantes basados en los modelos descriptivos de i) mínimos cuadrados ordinarios (OLSR), ii) LASSO y iii) RIDGE. Evalúe, tanto por validación cruzada como vía RMSE el desempeño de cada uno de tres los regresores. El reto consiste en obtener un error de regresión por debajo del 10%.

Haciendo uso del *dataset* de clasificación, implemente dos clasificadores que se ajusten vía SGD o alguna de sus variantes basados en los modelos descriptivos de i) regresión logística y ii) máquinas de vectores de soporte. Evalúe, tanto por validación cruzada como por *accuracy* el desempeño de cada uno de tres los clasificadores. El reto consiste en obtener una eficacia de clasificación por encima del 90%.

Se recomienda hacer uso de las funciones que provee el paquete *sci-kit learn* en Python:

https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.SGDClassifier.html
https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.SGDRegressor.html

6. BIBLIOGRAFÍA

- Shai, "Understanding Machine Learning: From Theory to Algorithms", chapter 14.

 Institución Universitaria	GUÍA DE TRABAJO PRÁCTICO - EXPERIMENTAL Talleres y Laboratorios de Docencia ITM	Código	FGL 029
		Versión	02
		Fecha	06-03-2019

- Burkov, "The hundred-page machine learning book", chapter 4.
- <https://machinelearningmastery.com/gradient-descent-for-machine-learning/>
- <https://machinelearningmastery.com/implement-linear-regression-stochastic-gradient-descent-scratch-python/>

Elaborado por:	Carlos Alejandro Trujillo Anaya
Revisado por:	Carlos Alejandro Trujillo Anaya
Versión:	001
Fecha:	Abril 5 de 2019