

Reconocimiento y clasificación

2019-I

Carlos Alejandro Trujillo Anaya – carlostrujillo@itm.edu.co

Oficina M212

Departamento de electrónica y telecomunicaciones


Asignatura perteneciente a Ingeniería electrónica

Viernes 18-20

Aula O2

Reconocimiento

Es el ajuste de una **etiqueta** a los objetos que se pueden detectar en una escena.




<http://innovacion.uas.edu.mx/vision-computacional-tecnologia-que-observa-hacia-el-futuro/>

Etiqueta: Indicador de la clase a la que pertenecen.

Tareas dentro del reconocimiento


Si sabemos que estamos buscando...



Detección de objetos

Tareas dentro del reconocimiento


Si deseamos reconocer la categoría general de los objetos...



Clasificación

<https://medium.com/zylapp/review-of-deep-learning-algorithms-for-object-detection-c1f3d437b852>

Ejemplos de reconocimiento



- Reconocimiento de rostros.
- Reconocimiento basado en instancias.
- Reconocimiento basado en características.
- Reconocimiento basado en regiones.
- Reconocimiento de escena.
- Reconocimiento por contexto

En el curso nos enfocaremos más en emplear clasificadores (machine learning).

Clasificación en aprendizaje de máquina




<https://www.kdnuggets.com/2017/05/machine-learning-crash-course-part-1.html>

Clasificación en aprendizaje de máquina

Objetivo: Determinar la frontera de decisión




Clasificación en aprendizaje de máquina



Al darle a nuestro clasificador ejemplos de naranjas y manzanas para que aprenda, el puede generalizar su experiencia para imágenes de manzanas y naranjas que nunca ha visto.

Desafíos de la clasificación en visión artificial

Iluminación



Es la misma escena para nosotros, pero no para un computador!

<http://www.perpetualvisions.com/cornucopia3d/atmospheres/atmospheres.htm>

Desafíos de la clasificación en visión artificial


Posición del objeto (Pose)



https://www.researchgate.net/figure/The-proposed-recognition-and-3D-pose-estimation-method-is-capable-of-generalizing-to_fig3_232707649

Desafíos de la clasificación en visión artificial

Oclusión



(a) Occluded Face 1




(c) Person

<https://stackoverflow.com/questions/2764238/image-processing-what-are-occlusions>

Desafíos de la clasificación en visión artificial

Apariencia entre instancias que pertenecen a la misma clase



https://www.reddit.com/r/MachineLearning/comments/8e4765/p_simple_tensorflow_implementation_of_multimodal/

Tareas exitosas en clasificación

Detección de rostros



Richard Szeliski, "Computer Vision: Algorithms and Applications", Chapter 14.

Tareas exitosas en clasificación


Detección de huellas dactilares



[http://cherup.yonsei.ac.kr/research/research_fake\(090528\).html](http://cherup.yonsei.ac.kr/research/research_fake(090528).html)

Tareas exitosas en clasificación

Detección de dígitos escritos



<https://medium.com/@himanshubeniwal/handwritten-digit-recognition-using-machine-learning-ad30562a9b64>

Clasificación supervisada



Cómo aprendemos los humanos?



Modificamos nuestro
comportamiento a partir de las
experiencias.

Clasificación supervisada


Ahora... y las máquinas?



**Las máquinas
siguen
instrucciones**


En particular, por máquina nos referiremos a los componentes de software y de hardware con los que cuenta un computador.

Los humanos podemos entrenar a las máquinas: Aprendizaje de Máquina



El aprendizaje de máquina es el estudio científico de algoritmos y modelos estadísticos que los sistemas informáticos utilizan para realizar de manera efectiva una tarea específica sin utilizar instrucciones explícitas, sino que se basan en patrones e inferencias.


Panorama general del *machine learning*



<https://www.ibm.com/co-es/analytics/machine-learning>

Panorama general del *machine learning*


TIPOS DE MACHINE LEARNING



<https://medium.com/ai-learners/ai-en-3-minutos-tipos-de-machine-learning-945b708ac78>

Algoritmos organizados por estilo de aprendizaje


Aprendizaje supervisado



Los datos de entrada se denominan datos de entrenamiento y tienen una etiqueta o resultado conocido, como spam / no-spam o un precio de acciones a la vez.

Algoritmos organizados por estilo de aprendizaje

Aprendizaje supervisado




Un modelo se prepara a través de un proceso de **entrenamiento** en el que se requiere hacer predicciones y se corrige cuando esas predicciones son erróneas.

El entrenamiento continúa hasta que el modelo alcanza el nivel deseado de precisión en los datos de entrenamiento.

Algoritmos organizados por estilo de aprendizaje

Aprendizaje supervisado




La clasificación y la regresión pertenecen a este tipo de algoritmos.

Ejemplo: Regresión logística y las redes neuronales.

Clasificadores


Existen los basados en modelos **generativos** y los basados en modelos **discriminativos**



https://www.researchgate.net/figure/An-illustration-of-the-difference-between-the-generative-and-discriminative-models-in_fig9_319093376

Descriptores

Todas las operaciones que se efectúen sobre las imágenes antes de introducirlas al clasificador dan como resultado una descripción de las mismas.



El histograma es uno de estos descriptores

Otros ejemplos?

Algoritmo Naive Bayes

En *machine learning*, una de las maneras más fáciles de seleccionar la hipótesis más probable es la información que tenemos (nuestro conjunto de entrenamiento) y que podemos utilizar como nuestro conocimiento **previo** sobre el problema.

$$P(C_k | x_i) = \frac{P(x | C_k)P(C_k)}{P(x)}$$

Diagram illustrating the Naive Bayes formula components:

- Probabilidad de los datos x dada la clase c_k (points to $P(x | C_k)$)
- Probabilidad a priori de la clase c_k (points to $P(C_k)$)
- Probabilidad a priori de los datos x (points to $P(x)$)
- Probabilidad posterior de la clase c_k dada la instancia x_i (points to $P(C_k | x_i)$)



Por ejemplo, una fruta puede considerarse una manzana si es roja, redonda y tiene 8 centímetros de diámetro.

Este algoritmo se basa en el teorema de Bayes, con la suposición de independencia entre predictores.

Algoritmo *Naive Bayes*

La representación de este modelo se hace en términos de probabilidades: Las probabilidades de cada clase y las probabilidades condicionales.

No hay que ajustar coeficientes en este modelo! El entrenamiento es **rápido**.

$P(C_k | x_i)$ Este es el valor que queremos calcular. Es la probabilidad de que la instancia x_i pertenezca a la clase c . Se calcula para cada clase. Al final se calcule la clase para la que esta probabilidad es **máxima**.

$P(x | C_k)$ Esta es la probabilidad de que los datos x aparezcan en la clase c .

$P(C_k)$ Esta es la probabilidad de la clase c .

$P(x)$ Esta es la probabilidad de los datos x , no depende de la clase, se puede eliminar.

Algoritmo Naive Bayes (Ejemplo)

Problema: Los jugadores entrenaran si el día está soleado. Esta hipótesis es correcta?

Weather	Play
Sunny	No
Overcast	Yes
Rainy	Yes
Sunny	Yes
Sunny	Yes
Overcast	Yes
Rainy	No
Rainy	No
Sunny	Yes
Rainy	Yes
Sunny	No
Overcast	Yes
Overcast	Yes
Rainy	No

Frequency Table		
Weather	No	Yes
Overcast		4
Rainy	3	2
Sunny	2	3
Grand Total	5	9

Likelihood table				
Weather	No	Yes		
Overcast		4	$=4/14$	0.29
Rainy	3	2	$=5/14$	0.36
Sunny	2	3	$=5/14$	0.36
All	5	9		
	$=5/14$	$=9/14$		
	0.36	0.64		

Algoritmo Naive Bayes (Ejemplo)

Problema: Los jugadores entrenaran si el día está soleado. Esta hipótesis es correcta?

Este problema lo podemos resolver con el método que acabamos de discutir.

$$P(\text{Si} \mid \text{Soleado}) = P(\text{Soleado} \mid \text{Si}) * P(\text{Si}) / P(\text{Soleado})$$

Aquí tenemos $P(\text{Soleado} \mid \text{Si}) = 3/9 = 0.33$, $P(\text{Soleado}) = 5/14 = 0.36$, $P(\text{Si}) = 9/14 = 0.64$

Ahora, $P(\text{Si} \mid \text{Soleado}) = 0.33 * 0.64 / 0.36 = 0.60$, la cual tiene una probabilidad más alta.

Algoritmo *Naive Bayes Gaussiano*

El teorema de *Bayes ingenuo* puede extenderse a los parámetros reales, más comúnmente asumiendo una distribución gaussiana asociada a los datos de cada clase.

Al trabajar con la distribución Gaussiana (o Normal) solo necesita estimar la media y la desviación estándar de cada una de las clases en los datos de entrenamiento.

$$\mu_k = \frac{\sum_{j=1}^n (x_j)}{n}$$

$$\sigma_k = \frac{\sqrt{\sum_{j=1}^n (x_j - \mu_k)^2}}{n - 1}$$

Algoritmo *Naive Bayes Gaussiano*


Para predecir con este modelo, empleamos la función de densidad de probabilidad (PDF) Gaussiana.

$$p(x = v \mid C_k) = \frac{1}{\sqrt{2\pi\sigma_k^2}} e^{-\frac{(v-\mu_k)^2}{2\sigma_k^2}}$$


Y finalmente podemos aplicar

$$P(C_k \mid x_i) = \frac{P(x \mid C_k)P(C_k)}{P(x)}$$

k-NN (k-nearest neighbor)



k-NN (k-nearest neighbor)




Example

- $k = 3$
- classes 'a' and 'o'
- find class for 'c'

k-NN (k-nearest neighbor)

When $k = 1$, each training vector defines a region in space, defining a *Voronoi* partition of the space




$$R_i = \{x : d(x, x_i) < d(x, x_j), i \neq j\}$$

Remarks

- chose an odd k value for a 2 class problem
- k must not be a multiple of the number of classes
- the main drawback of k NN is the complexity in searching the nearest neighbors for each sample

Árboles de decisión



En esta técnica dividimos las instancias en distintos conjuntos homogéneos basándonos en características diferenciadoras en el conjunto de entrenamiento.



<https://www.analyticsvidhya.com/blog/2016/04/complete-tutorial-tree-based-modeling-scratch-in-python/>

Problema: Identificar los personajes como buenos o malos según su apariencia.

	sex	mask	cape	tie	ears	smokes	class
training data							
batman	male	yes	yes	no	yes	no	Good
robin	male	yes	yes	no	no	no	Good
alfred	male	no	no	yes	no	no	Good
penguin	male	no	no	yes	no	yes	Bad
catwoman	female	yes	no	no	yes	no	Bad
joker	male	no	no	no	no	no	Bad
test data							
batgirl	female	yes	yes	no	yes	no	??
riddler	male	yes	no	no	no	no	??



Rob Schapire, Princeton University .

Escoja una **regla** para dividir los datos en subconjuntos separados



La idea es obtener subconjuntos de datos que sean **puros**.


El problema clave consiste en escoger **adecuadamente** la regla de division... difícil en la realidad!




Esta regla debe escoger considerando la **pureza** de los subconjuntos.

Un posible clasificador podría ser uno de los siguientes:


Clasificador **complejo**



Clasificador **simple**



Tamaño del árbol vs error de clasificación



El tamaño del árbol debe ser suficientemente grande para que se ajuste a los datos, pero no tan grande como para que sobreestimen (*overfit*).

Random forest

Se puede entender como un gran compendio de árboles de decisión que no están correlacionados.


$$S = \begin{bmatrix} f_{A1} & f_{B1} & f_{C1} & C_1 \\ \vdots & & \vdots & \\ f_{AN} & f_{BN} & f_{CN} & C_N \end{bmatrix}$$

feature A of the 1st sample

feature B of the Nth sample


Random forest

Se crean subconjuntos con muestras distintas de forma aleatoria (para crear muchos árboles: “Forest”).





Random forest


Class prediction



result is
class 1




Máquinas de vectores de soporte (SVM)



Problema de clasificación binario
con dos conjunto linealmente
separables (ideal).


Thales Sehn Körting

Máquinas de vectores de soporte (SVM)




El objetivo es obtener el hiperplano que mejor nos permita clasificar las muestras entre las dos clases.

Máquinas de vectores de soporte (SVM)




El objetivo es obtener el hiperplano que mejor nos permita clasificar las muestras entre las dos clases.

Máquinas de vectores de soporte (SVM)



Es decir, el hiperplano que provee el mayor **margen**.

Máquinas de vectores de soporte (SVM)



$$g(\vec{x}) \geq 1, \quad \forall \vec{x} \in \text{class 1}$$

$$g(\vec{x}) \leq -1, \quad \forall \vec{x} \in \text{class 2}$$

$$z = \frac{|g(\vec{x})|}{\|\vec{w}\|} = \frac{1}{\|\vec{w}\|}$$

Si el margen total es

$$\frac{1}{\|\vec{w}\|} + \frac{1}{\|\vec{w}\|}$$


El objetivo entonces es minimizar

$$\|\vec{w}\|$$

Máquinas de vectores de soporte (SVM)

$$g(\vec{x}) \geq 1, \quad \forall \vec{x} \in \text{class 1}$$

$$g(\vec{x}) \leq -1, \quad \forall \vec{x} \in \text{class 2}$$



El objetivo entonces es minimizar


$$\|\vec{w}\|$$

$$\vec{w} = \sum_{i=0}^N \lambda_i y_i \vec{x}_i$$

$$\sum_{i=0}^N \lambda_i y_i = 0$$

Esta es una tarea de optimización no lineal que se lleva a cabo empleando los **multiplicadores de Lagrange**


Redes neuronales artificiales



Las redes neuronales artificiales son modelos inspirados en la estructura y/o función de las redes neuronales biológicas.


https://cdn-images-1.medium.com/max/1200/1*eBMwpBBboAXgqsawwOKkPw.png

Redes neuronales artificiales



Estos algoritmos se basan en el acople de patrones y se usan comúnmente para problemas de regresión y clasificación, pero en realidad son un sub-campo enorme que consta de cientos de algoritmos y variaciones para todo tipo de problemas.

Redes neuronales artificiales



Los algoritmos (clásicos) más populares son:


Perceptron

Back-Propagation

Hopfield Network

Radial Basis Function Network (RBFN)



Algoritmos de deep learning



Se preocupan por construir redes neuronales mucho más grandes y complejas.

Muchos métodos se ocupan de problemas de aprendizaje semi-supervisados donde los conjuntos de datos grandes contienen muy poca información etiquetada.

Algoritmos de deep learning



Los algoritmos de *deep learning* más populares son:

Deep Boltzmann Machine (DBM)

Deep Belief Networks (DBN)

Convolutional Neural Network (CNN)

Stacked Auto-Encoders

<https://medium.com/swlh/ill-tell-you-why-deep-learning-is-so-popular-and-in-demand-5aca72628780>

Referencias

Richard Szeliski, “Computer Vision: Algorithms and Applications”, Chapter 14.

Forsyth and Ponce, “Computer vision a modern approach”. Chapter 20.

Andriy Burkov, “The hundred-page machine learning book”. Chapters 3, 4, 5 and 6.

<https://classroom.udacity.com/courses/ud810/>