

 Institución Universitaria	GUÍA DE TRABAJO PRÁCTICO - EXPERIMENTAL Talleres y Laboratorios de Docencia ITM	Código	FGL 029
		Versión	02
		Fecha	06-03-2019

1. IDENTIFICACIÓN DE LA GUÍA

Nombre de la guía:	Talleres evaluativos de Visión Artificial
Código de la guía (No.):	005
Taller(es) o Laboratorio(s) aplicable(s):	Taller evaluativo individual acerca de clasificación en visión por computador.
Tiempo de trabajo práctico estimado:	7 días (Entrega: Mayo 21 de 2019 antes 20 horas)
Asignatura(s) aplicable(s):	Visión Artificial VAW82-1
Programa(s) Académico(s) / Facultad(es):	Ingeniería electrónica/ Departamento de electrónica y telecomunicaciones
Docente encargado	Carlos Alejandro Trujillo Anaya
Porcentaje evaluado de la asignatura	10%

COMPETENCIAS	CONTENIDO TEMÁTICO	INDICADOR DE LOGRO
El estudiante implementa algoritmos de clasificación para su implementación sobre imágenes y/o videos.	Reconocimiento en imágenes. Detección de objetos. Descriptor de imágenes. Aprendizaje supervisado. Modelos generativos y discriminativos. Clasificadores en aprendizaje de máquina.	El estudiante lleva a cabo la tarea de clasificación sobre una imagen o un parche de la misma, con el fin de detectar o reconocer objetos particulares previamente definidos.

2. INTRODUCCION

De todas las tareas que se pueden llevar a cabo en visión artificial, analizar una escena y reconocer todos los objetos presentes en ella sigue siendo **la más difícil**. Aunque se han implementado propuestas en visión por computador que llevan a cabo satisfactoriamente la tarea de reconstruir con precisión la forma 3D de una escena, ya sea con visión estéreo o con holografía digital, la tarea de nombrar todos los objetos presentes en la misma, incluso en ese punto, sigue siendo altamente desafiante. De hecho, en el estado del arte no hay consenso sobre cuándo se alcanzará este nivel de rendimiento por parte de los computadores. En los últimos años el *deep learning* ha dado cuenta de lo anterior y, en situaciones controladas, se han diseñado clasificadores que han otorgado soluciones tecnológicamente aceptables al problema, sin embargo, no son soluciones definitivas.

Entonces, ¿por qué es tan difícil la tarea de clasificación en visión por computador? El mundo real está hecho de una mezcla de objetos, que se **ocluyen** unos a otros y aparecen en **diferentes posiciones**. Igualmente, la **variabilidad** intrínseca dentro de una clase (por ejemplo, la clase *perros*), debido a la compleja articulación no rígida, así como las variaciones extremas de forma y apariencia (las cuales ocurren entre sus diferentes razas, por ejemplo), hace que sea poco probable solucionar el problema de la detección o clasificación de objetos, simplemente realizando una comparación exhaustiva con una base de datos de imágenes muestras.

 Institución Universitaria	GUÍA DE TRABAJO PRÁCTICO - EXPERIMENTAL Talleres y Laboratorios de Docencia ITM	Código	FGL 029
		Versión	02
		Fecha	06-03-2019

Más allá de lo anterior, existen algunas tareas que se llevan a cabo exitosamente empleando técnicas de clasificación en problemas de visión por computador. Una de estas tareas es la **detección de rostros**. La tecnología actual de reconocimiento facial se basa principalmente en el trabajo de Paul Viola y Michael Jones, quienes lograron un gran avance en 2001 cuando desarrollaron un algoritmo que podía detectar rostros en tiempo real. Sin embargo, su método, que se basa en la identificación rápida de una serie de patrones asociados con la cara humana, se limita a caras totalmente visibles ubicadas perfectamente frente a la cámara. Algoritmos más actuales basados en *deep learning*, como el *Deep Dense Face Detector*, llevan a cabo esta tarea en tiempo real sobre imágenes con caras en distintas posiciones, distintas condiciones de iluminación y con distintos grados de oclusión. En el campo del *natural language processing*, la correcta clasificación y reconocimiento de **dígitos escritos a mano** ha sido ampliamente estudiada. De nuevo, clasificadores basados en *deep learning* ejecutan la tarea con precisiones de clasificación por encima del 99%.

Para la solución de problemas generales de clasificación en visión por computador, se han diferenciado tradicionalmente los clasificadores entre aquellos basados en **modelos generativos** y aquellos basados en **modelos discriminativos**. Los primeros consisten en el modelamiento de los patrones que representan a cada clase a identificar en términos de las funciones de densidad condicional de que una instancia dada pertenezca a la clase en cuestión. Estos clasificadores construyen sus modelos esencialmente calculando estadísticas sobre los conjuntos de imágenes de entrenamiento. Son los clasificadores más tradicionales ya que su complejidad computacional no es tan grande, sin embargo su precisión no es la más alta en muchos problemas. Por otro lado, los clasificadores basados en modelos discriminativos, buscan maximizar la precisión de clasificación de la salida para una imagen dada, empleando un ajuste sistemático de los parámetros que constituyen el modelo, en lo que se denomina el **entrenamiento** del clasificador. Dependiendo de la calidad del conjunto de imágenes de entrenamiento y del clasificador empleado, los resultados de precisión de clasificación para los modelos discriminativos son muy superiores a los modelos generativos, eso sí, con complejidades computacionales mucho mayores.

Con el fin de reducir la complejidad computacional de un clasificador, se hace uso generalmente de **descriptores** visuales. Estos algoritmos se emplean sobre las imágenes antes de que las mismas sean procesadas por un clasificador. En términos generales, los descriptores buscan representar los datos más relevantes de una imagen, los cuales podrían facilitar la tarea de clasificación, en un espacio dimensionalmente más pequeño. Uno de los descriptores básicos más utilizados es el histograma. El histograma representa una imagen en términos del número de píxeles que tienen la misma intensidad de gris (o de cada componente si se trabaja con una imagen RGB), para todas las intensidades posibles. Una clasificación, por ejemplo, entre imágenes del océano e imágenes de montañas podría facilitarse enormemente empleando este descriptor.

Una vez las imágenes han sido **pre-procesadas** empleando algún descriptor, los datos resultantes están listos para suministrarse al clasificador. En particular, en el curso daremos prioridad a los clasificadores derivados de las técnicas del **aprendizaje de máquina**. El aprendizaje de máquina ha tenido una gran influencia en la tarea de clasificación en visión por computador, de hecho, las tareas en esta área con mejor desempeño dan cuenta de un clasificador de esta índole. Ejemplos de estos clasificadores son: i) el **Naive Bayes**, que construye un modelo generativo para cada clase empleando probabilidades a priori para la clase y para la instancia. ii) El **k-NN** que construye su modelo empleando las muestras del conjunto de entrenamiento para definir un espacio de características en el cual las nuevas imágenes se ubican y se clasifican de acuerdo a sus vecinos. iii) Los **árboles de decisión** y el **random forest**, los cuales se basan en la construcción de sus modelos en términos de reglas discriminantes empleadas sobre las características. iv) Las **máquinas de vectores de soporte** que construyen modelos discriminativos que representan a las imágenes muestra con puntos en el espacio de características, separando las distintas clases en sub-espacios lo más alejados posibles mediante un **hiperplano** de separación. Cuando nuevas imágenes se clasifican con el modelo, en función de los espacios a los que pertenezcan, pueden ser clasificadas en una clase dada. v) Las **redes neuronales** y el **deep learning**, las

 Institución Universitaria	GUÍA DE TRABAJO PRÁCTICO - EXPERIMENTAL Talleres y Laboratorios de Docencia ITM	Código	FGL 029
		Versión	02
		Fecha	06-03-2019

cuales construyen modelos discriminativos tipo *caja negra* empleando conexiones entre unidades que reciben y proveen valores reales llamadas neuronas. Dependiendo de la configuración, de las funciones de activación que involucran, y mayormente, de la complejidad del modelo las redes neuronales se distinguen entre las redes más simples como los *perceptrones* o las más elaboradas como las *convolucionales*. Las redes neuronales artificiales involucran un modelo en el que se ajusta el valor de cada una de sus neuronas iterativamente empleando el conjunto de imágenes de entrenamiento. Actualmente, las soluciones relaciones con el reconocimiento y la detección en visión por computador con mayor eficacia se basan en las **redes neuronales convolucionales**, una subdivisión de los algoritmos de *deep learning*, en la cual las imágenes no necesitan ningún tipo de pre-procesamiento ya que la misma red lleva a cabo la **extracción de características** necesaria.

3. OBJETIVO(S)

- Clasificar imágenes o parches de las mismas con el fin de reconocer o detectar objetos particulares en las escenas representadas.

4. RECURSOS REQUERIDOS

- Un computador con un compilador de Python actualizado y con la librería de *openCV* completamente funcional.
- Un computador con un editor de texto para la redacción del informe.

5. PROCEDIMIENTO

En un script de *Python*, implemente un algoritmo que le permita reconocer o detectar un objeto particular en un conjunto de imágenes empleando un clasificador. Esta actividad está íntimamente ligada al desarrollo del proyecto final de la asignatura. Debido a lo anterior, establezca lo siguiente:

1. Título del proyecto final de la signatura que le fue aprobado.
2. Tarea de clasificación que debe llevar a cabo en una de las etapas de la implementación de su proyecto final.
3. Conjuntos de imágenes que empleará para entrenar y para validar el clasificador.
4. Objeto que desea detectar o reconocer en dicho conjunto de imágenes.
5. Algoritmo de clasificación a implementar.

Ya que esta actividad se propone como un insumo para su proyecto final, la tarea de clasificación que llevará a cabo debe tener una eficacia suficiente para hacer uso de la misma en su proyecto. Igualmente, la misma debe estar orientada a una clasificación en tiempo real, o en su defecto, a ratas de procesamiento tecnológicamente atractivas.

Para la elaboración de esta actividad, puede considerar los clasificadores en *openCV*:

https://docs.opencv.org/3.4.2/d5/d26/tutorial_py_knn_understanding.html
https://docs.opencv.org/2.4/modules/ml/doc/normal_bayes_classifier.html#cvnormalbayesclassifier
https://opencv-python-tutroals.readthedocs.io/en/latest/py_tutorials/py_ml/py_svm/py_svm_opencv/py_svm_opencv.html
https://docs.opencv.org/2.4/modules/ml/doc/random_trees.html
<https://www.learnopencv.com/image-classification-using-feedforward-neural-network-in-keras/>

O los clasificadores pre-entrenados que existen en la literatura:

 Institución Universitaria	GUÍA DE TRABAJO PRÁCTICO - EXPERIMENTAL Talleres y Laboratorios de Docencia ITM	Código	FGL 029
		Versión	02
		Fecha	06-03-2019

<https://www.pyimagesearch.com/2017/08/21/deep-learning-with-opencv/>

6. PARÁMETROS PARA LA ENTREGA

El informe debe contener una **breve** descripción del método implementado. El texto debe tener estructura de artículo científico y no debe superar las 3 hojas de extensión.

Entregue las imágenes empleadas, así como el *script* elaborado y el informe en un archivo comprimido al correo carlostrujillo@itm.edu.co.

7. BIBLIOGRAFÍA

- Richard Szeliski, "Computer Vision: Algorithms and Applications", Chapter 14.
- Forsyth and Ponce, "Computer vision a modern approach". Chapter 20.
- Andriy Burkov, "The hundred-page machine learning book". Chapters 3, 4, 5 and 6.
- <https://classroom.udacity.com/courses/ud810/>

Elaborado por:	Carlos Alejandro Trujillo Anaya
Revisado por:	Carlos Alejandro Trujillo Anaya
Versión:	001
Fecha:	Mayo 12 de 2019